Universidad Privada Franz Tamayo

Facultad de Ingeniería

Carrera de Ingeniería de Sistemas

Limpieza y validación de datos para minería de datos

Informe de laboratorio del Hito 3

Josias Fidel Quispe Yauripara

Flor Jaque Ibarra

Asignatura: Mineria de Datos

La Paz – Bolivia 2026

Introducción

La práctica permitió depurar un conjunto de 210 registros y 10 variables mediante Python. El proceso eliminó 10 filas duplicadas, estandarizó nombres y categorías, trató edades e ingresos inválidos y convirtió fechas. El archivo resultante contiene 200 registros y conserva 45 valores faltantes que requieren verificación en la fuente. Estos resultados muestran una mejora en la calidad estructural de los datos, aunque no garantizan la veracidad de cada registro.

El trabajo sigue la secuencia del material Lab_hito 3 (s. f.): carga, diagnóstico, selección de tratamientos, limpieza, validación y exportación. El análisis se realizó sobre dataset_con_errores.csv, conservando el archivo original y trabajando sobre una copia en memoria. Las cifras de este informe corresponden a la salida de ejecución del programa practica.py.

Objetivos

Objetivo general

Identificar y tratar problemas de calidad en un conjunto de datos mediante un procedimiento reproducible de limpieza en Python, para mejorar su preparación antes de un análisis de minería de datos.

Objetivos específicos

Describir las variables y cuantificar valores faltantes, duplicados y valores fuera de los rangos establecidos.

Aplicar tratamientos justificados para categorías, valores numéricos y fechas.

Comparar el estado inicial y final, exportar el archivo limpio y documentar las limitaciones del proceso.

Materiales y descripción de los datos

Se utilizó Visual Studio Code con una terminal de PowerShell, Python y las bibliotecas pandas y NumPy. La instalación se realizó mediante python -m pip install pandas numpy y la ejecución mediante python practica.py. No se registraron las versiones exactas del entorno en la evidencia disponible.

El archivo de entrada fue dataset_con_errores.csv y el archivo de salida fue dataset_limpio.csv. Ambos se ubican en la carpeta Lab_hito3. El identificador distingue registros y no debe tratarse como una magnitud cuantitativa para el modelado.

Tabla 1

Descripción de las variables

Variable	Tipo conceptual	Descripción
id	Identificador	Código del registro
nombre	Texto	Nombre de la persona
edad	Numérica	Edad expresada en años
genero	Categórica	Género registrado
pais	Categórica	País registrado
ingresos	Numérica	Importe con formatos heterogéneos
fecha_nacimiento	Temporal	Fecha en distintos formatos
email	Texto	Correo electrónico
telefono	Texto	Número de contacto
categoria	Categórica	Clasificación A, B, C o D

Nota. Las variables ingresos y fecha_nacimiento se cargaron como texto debido a sus formatos. La clasificación conceptual describe su significado y no necesariamente su tipo inicial en pandas.

Diagnóstico de calidad

Se revisaron la estructura, las frecuencias de categorías y las estadísticas descriptivas. Los conteos iniciales incluyen las 210 filas, por lo que contienen registros duplicados. Una fila puede presentar varios problemas; por ello, las cantidades de errores no representan personas distintas.

Tabla 2

Problemas identificados antes de la limpieza

Problema	Columna	Cantidad
Valores faltantes	Todas	83
Filas completamente duplicadas	Todas	10
Edades fuera de 18 a 100	edad	6
Ingresos fuera de 0 a 200 000	ingresos	6
Fechas no interpretables	fecha_nacimiento	2
Correos con formato incorrecto	email	27
Formatos distintos sin nulos	genero	10
Formatos distintos sin nulos	pais	13

Las edades fuera del rango incluyeron 0, 150 y 999 años. Los ingresos observados incluyeron −1000, 1000000 y 9999999. Estas observaciones se clasificaron según las reglas del laboratorio; no se utilizó un detector estadístico de valores atípicos como el rango intercuartílico.

Las categorías mostraron diferencias por mayúsculas, espacios, abreviaturas y tildes. En ingresos se encontraron símbolos monetarios y separadores de miles. No se detectaron edades ni ingresos no convertibles a número después de retirar los símbolos contemplados por el programa.

Tratamientos y ejecución de la limpieza

Conservación del original y eliminación de duplicados

Se reconocieron las celdas compuestas solo por espacios como valores faltantes. Luego se creó df_limpio mediante base.copy(). Esta copia en memoria permitió aplicar

transformaciones sin sobrescribir el CSV original. Con drop_duplicates() se eliminaron 10 filas completamente iguales, obteniendo 200 registros.

Normalización de nombres y categorías

Los nombres se procesaron con strip() y title(). El género se convirtió a minúsculas, se retiraron espacios y se aplicó un diccionario para unificar las variantes en Masculino y Femenino. Se completaron 13 valores faltantes con la moda Masculino. Los países se normalizaron a México, Argentina, Colombia y España.

Tratamiento de edad e ingresos

Se marcaron como nulas las edades menores de 18 o mayores de 100. Después de eliminar duplicados, existían 15 edades faltantes y 5 inválidas; se completaron 20 valores con la mediana de 43 años. Las edades se redondearon y se almacenaron como enteros con soporte de valores nulos.

En ingresos se retiraron USD, $, € y las comas de miles. Los importes menores de 0 o mayores de 200000 se marcaron como nulos. Se completaron 14 valores: 10 faltantes y 4 fuera de rango, con una mediana de 27167,97. La mediana se calculó con los importes válidos restantes, después de eliminar duplicados.

Conversión de fechas

Se interpretaron formatos con año primero y formatos con día o mes primero. Ante una fecha ambigua se priorizó el día, conforme al criterio de la guía. Las 2 fechas no interpretables se conservaron como nulas, junto con las 6 fechas originalmente vacías. El archivo exportado utiliza el formato año-mes-día.

Validación y resultados finales

Tabla 3

Comparación de indicadores generales

Indicador	Antes	Después
Registros	210	200
Columnas	10	10
Filas duplicadas	10	0
Valores faltantes	83	45
Edades fuera del rango	6	0
Ingresos fuera del rango	6	0

Tabla 4

Valores faltantes por variable

Variable	Antes	Después
id	0	0
nombre	0	0
edad	15	0
genero	14	0
pais	0	0
ingresos	11	0
fecha_nacimiento	6	8
email	16	16
telefono	21	21
categoria	0	0

Nota. El aumento de fechas nulas se debe al reconocimiento de dos valores inválidos. Los 45 faltantes finales corresponden a 8 fechas, 16 correos y 21 teléfonos. La conservación de estos vacíos evita sustituir información desconocida por datos inventados.

La exportación se realizó con to_csv(), index=False y encoding="utf-8-sig". El archivo dataset_limpio.csv conserva las 10 variables y no incorpora una columna adicional de índice.

Interpretación técnica y análisis final

La proporción de celdas faltantes pasó de 83/(210 × 10) × 100 = 3,95 % a 45/(200 × 10) × 100 = 2,25 %. Este indicador describe completitud, no exactitud. La eliminación de duplicados y la imputación contribuyeron al cambio, mientras que la conversión de fechas hizo explícitos dos errores adicionales.

La edad final presenta una media de 42,945 años, mediana de 43, mínimo de 18 y máximo de 69. Los ingresos presentan una media de 27459,10, mediana de 27167,97 y valores entre 5546,95 y 49987,30. El género se distribuye en 108 registros Masculino y 92 Femenino. Los países registran 54 casos de México, 50 de Argentina, 49 de Colombia y 47 de España.

Aspecto de mayor dificultad

El aspecto técnicamente más delicado fue interpretar fechas e ingresos con formatos heterogéneos. Una fecha como 04-02-1952 admite dos interpretaciones; el programa prioriza día-mes-año, pero esa decisión debe contrastarse con la fuente. Asimismo, retirar un símbolo monetario permite convertir texto a número, pero no convierte monedas.

Limitaciones y preparación para minería de datos

El resultado conserva correos incorrectos y teléfonos faltantes para revisión. Tampoco se verificó la correspondencia entre edad y fecha de nacimiento. Los importes solo pueden compararse económicamente si representan una moneda común; de existir monedas distintas, deben confirmarse y convertirse antes del análisis.

La imputación introduce estimaciones y puede modificar las distribuciones. Para un modelo predictivo posterior, la moda y las medianas deben calcularse únicamente con el

conjunto de entrenamiento y aplicarse a los demás conjuntos, evitando utilizar información de evaluación durante el ajuste del preprocesamiento.

Conclusiones

La práctica cumplió la secuencia de carga, diagnóstico, tratamiento, validación y exportación. Se redujo el conjunto de 210 a 200 registros mediante la eliminación de duplicados, se unificaron categorías y se trataron los valores numéricos fuera de los rangos establecidos. El archivo original se conservó y el resultado se guardó por separado.

La limpieza es necesaria antes de entrenar un modelo porque los duplicados pueden dar peso excesivo a ciertos registros, los formatos diferentes pueden crear categorías artificiales y los valores extremos inválidos pueden distorsionar las estadísticas. La preparación debe documentarse para que las transformaciones puedan revisarse y reproducirse.

El archivo obtenido mejora la consistencia del conjunto, pero mantiene 45 valores faltantes y problemas semánticos pendientes. Por ello, su uso en minería de datos debe acompañarse de una revisión de contactos, fechas y moneda de los ingresos. Completar un campo no equivale a verificar su valor real.

Gestión de tareas

Completado: instalación e importación de pandas y NumPy; carga del dataset.

Completado: identificación de nulos y conteo de duplicados.

Completado: limpieza de nombre, genero, pais, edad e ingresos.

Completado: conversión de fecha_nacimiento y validación de resultados.

Completado: exportación de dataset_limpio.csv.

Apéndice A

Evidencias de carga y diagnóstico

Figura 1

Carga del archivo y descripción de las variables

```
========== PASO 2: CARGA DEL DATASET ==========
Filas: 210
Columnas: 10

Primeras 5 filas:
   id   nombre  edad  ...              email          telefono categoria
0   1   carlos  56.0  ...   carlos0@gmail.com  +52 194 648 4120         D
1   2      Ana  69.0  ...      ana1@yahoo.com     +521409942192         C
2   3    Laura  46.0  ...  laura2@hotmail.com     +526723228854         A
3   4     José  32.0  ...   josé3@hotmail.com               NaN         D
4   5   JOSÉ    60.0  ...    josé4aoutlookcom  +52 590 348 4350         B

[5 rows x 10 columns]

Descripción de las variables:
id: Identificador del registro
nombre: Nombre de la persona
edad: Edad en años
genero: Género registrado
pais: País registrado
ingresos: Ingreso registrado
fecha_nacimiento: Fecha de nacimiento
email: Correo electrónico
telefono: Número de teléfono
categoria: Categoría asignada
```

Figura 2

Diagnóstico inicial de calidad de los datos

```
Información general:
<class 'pandas.DataFrame'>
RangeIndex: 210 entries, 0 to 209
Data columns (total 10 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   id                210 non-null    int64
 1   nombre            210 non-null    str
 2   edad              195 non-null    float64
 3   genero            196 non-null    str
 4   pais              210 non-null    str
 5   ingresos          199 non-null    str
 6   fecha_nacimiento  204 non-null    str
 7   email             194 non-null    str
 8   telefono          189 non-null    str
 9   categoria         210 non-null    str
dtypes: float64(1), int64(1), str(8)
memory usage: 16.5 KB
```

```
 Valores faltantes por columna:
 id                  0
 nombre              0
 edad               15
 genero             14
 pais                0
 ingresos           11
 fecha_nacimiento    6
 email              16
 telefono           21
 categoria           0
 dtype: int64

 Total de valores faltantes: 83
 Filas duplicadas: 10

 Estadísticas de edad:
 count    195.000000
 mean      47.558974
 std       70.749524
 min        0.000000
 25%       29.500000
 50%       43.000000
 75%       56.000000
 max      999.000000
 Name: edad, dtype: float64
```

```
Edades fuera del rango 18–100:
Cantidad: 6
       id  nombre   edad
15     16    José    0.0
33     34    josé  999.0
49     50  Carmen  150.0
57     58    José    0.0
166   167  Carlos    0.0
201    16    José    0.0
Edades no numéricas: 0

Formatos de género:
genero
MASCULINO     27
FEMENINO      26
Femenino      24
Masculino     20
Masculino     20
 femenino     20
m             19
M             15
NaN           14
f             13
F             12
Name: count, dtype: int64
```

```
Formatos de pais:
pais
Argentina     23
COLOMBIA      18
argentina     18
colombia      17
Colombia      17
España        17
ESPAÑA        17
españa        16
mexico        16
México        15
MÉXICO        13
 Mexico       12
ARGENTINA     11
Name: count, dtype: int64
```

```
Ingresos fuera del rango 0–200000:
Cantidad: 6
      id       ingresos
45    46      1000000.0
70    71  $9,999,999.00
158  159      9999999.0
172  173        -1000.0
203  159      9999999.0
209   46      1000000.0
Ingresos no numéricos: 0

Fechas no interpretables: 2
Correos con formato incorrecto: 27
```

```
Fechas no interpretables: 2
Correos con formato incorrecto: 27

Tratamientos que se aplicarán:
- Duplicados: eliminar filas completamente iguales.
- Nombres: quitar espacios y aplicar formato título.
- Género: unificar formatos y completar con la moda.
- País: unificar su escritura.
- Edad: invalidar valores fuera de 18–100 y usar la mediana.
- Ingresos: limpiar formatos, aplicar rango y usar la mediana.
- Fechas: convertir formatos y dejar vacías las inválidas.
- Correos y teléfonos: conservar para revisión, sin inventar datos.
```

Apéndice B

Evidencias de limpieza y exportación

Figura 3

Tratamientos aplicados y valores de imputación

```
4.2. Duplicados eliminados: 10

4.3. Nombres limpios:
0    Carlos
1       Ana
2     Laura
3      José
4      José
5     María
6    Carlos
7    Carmen
8    Carlos
9    Miguel
Name: nombre, dtype: string

4.4. Moda de género: Masculino
Géneros completados: 13

4.5. Países estandarizados:
pais
México       54
Argentina    50
Colombia     49
España       47
Name: count, dtype: int64

4.6. Mediana de edad: 43.0
Edades completadas: 20

4.7. Mediana de ingresos: 27167.97
Ingresos completados: 14
```

```
4.8. Fechas convertidas:
0   2012-12-17
1   2008-07-24
2   1991-04-06
3   1952-02-04
4   1997-06-10
5   1989-02-14
6   1966-11-03
7          NaT
8   1993-11-23
9   1956-01-08
Name: fecha_nacimiento, dtype: datetime64[us]
```

Figura 4

Validación final y archivo exportado

```
Dimensiones:
Filas antes: 210
Filas después: 200
Columnas: 10

Comparación de valores faltantes:
                  Nulos antes  Nulos después
id                          0              0
nombre                      0              0
edad                       15              0
genero                     14              0
pais                        0              0
ingresos                   11              0
fecha_nacimiento            6              8
email                      16             16
telefono                   21             21
categoria                   0              0

Total de nulos antes: 83
Total de nulos después: 45

Duplicados después de limpiar:
0

Géneros finales:
genero
Masculino    108
Femenino      92
Name: count, dtype: int64

Países finales:
pais
México       54
Argentina    50
Colombia     49
España       47
Name: count, dtype: int64
```

```
Estadísticas finales de ingresos:
count           200.0
mean     27459.096868
std      13325.720763
min       5546.951361
25%      15677.146196
50%          27167.97
75%      39052.877379
max           49987.3
Name: ingresos, dtype: Float64

Edades fuera del rango después de limpiar:
0

Ingresos fuera del rango después de limpiar:
0

Observaciones:
- Las fechas inválidas o desconocidas permanecen vacías.
- Las fechas ambiguas se interpretaron con el día primero.
- Los correos incorrectos y teléfonos faltantes requieren revisión.
- No se verificó la correspondencia entre edad y fecha de nacimiento.
```

```
========== PASO 6: ARCHIVO GUARDADO ==========
Archivo: dataset_limpio.csv
Ubicación: C:\Users\Usuario\OneDrive\Desktop\Lab_hito3\dataset_limpio.csv
```